

Отчет по машинному обучению

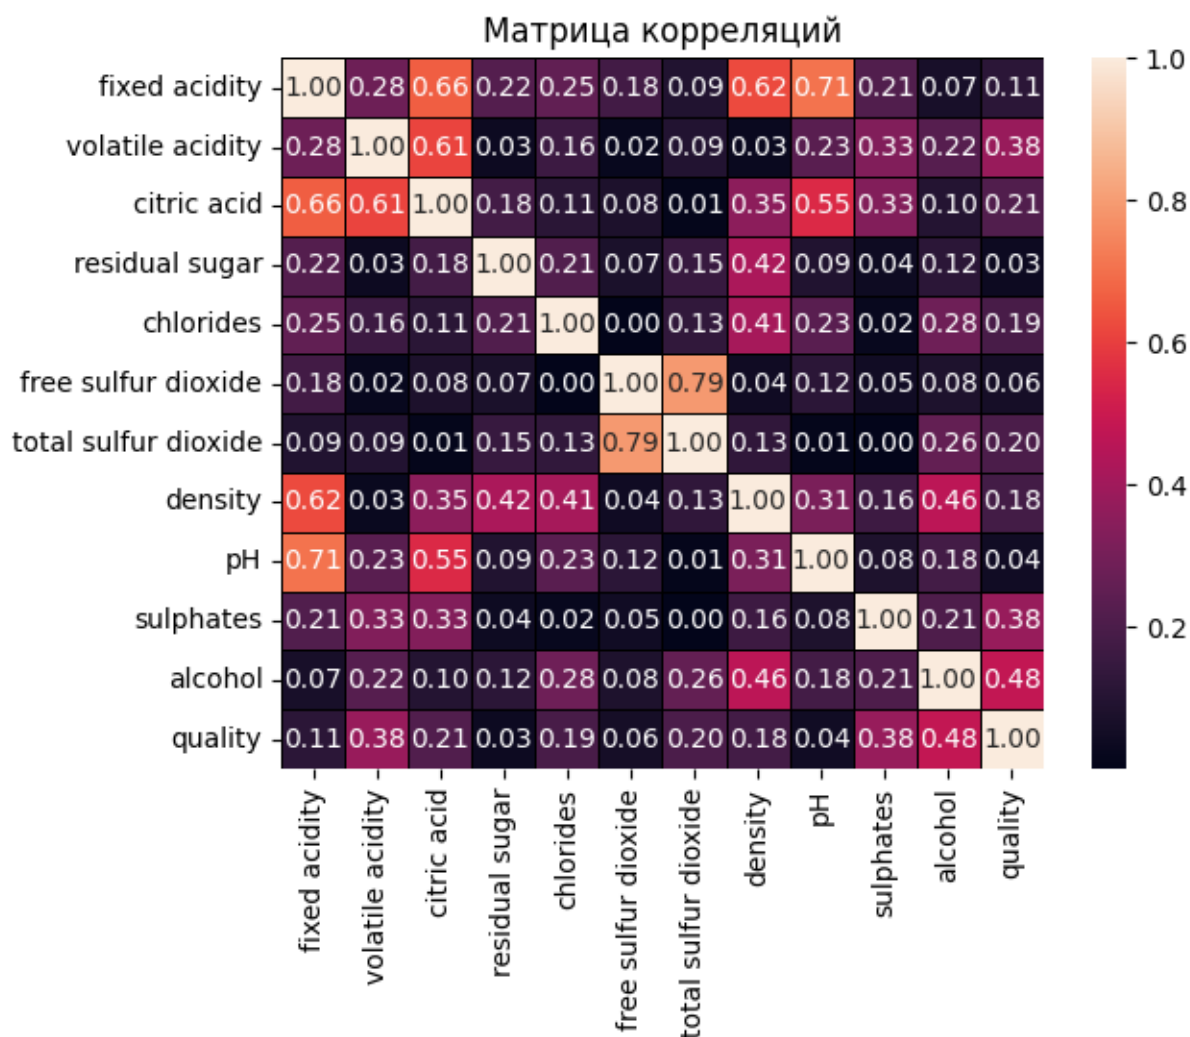
Задание: Проанализировать датасет

В качестве датасета была взята информация о качестве красного вина и его различных характеристиках. В данной работе были проведены следующие действия:

- Построена матрица корреляций числовых параметров вина
- Построены boxplot графики для всех числовых параметров, а также подсчитано количество выбросов и подсчитана доля этих выбросов
- Построены графики частот всех численных параметров (также можно считать это графиками распределения значений параметров вина)
- Построены QQ-линии
- Построены pairplot графики
- Сделаны некоторые выводы о некоторых параметрах и взаимосвязи этих параметров


Ниже представлены выше изложенные графики

Матрица корреляций



Выводы: параметры свободных и общих оксидов серы, нелетучие кислоты и pH вместе с плотностью и лимонной кислотой имеют высокую корреляцию

Boxplot




Данные графики дают представление о распределении параметров красного вина. Например, из-за относительной симметрии графика для параметра плотности можно предположить о нормальности распределения. Также можно сказать и о параметре pH.

Про параметры лимонной кислоты, алкоголя и общих оксидов серы можно сказать о асимметрии распределения величин.


Более подробно о распределении величин будет видно на графиках ниже.

Графики распределений



По графикам отчетливо можно сказать, что вероятно параметры плотности и pH подчиняются нормальному распределению. Данную гипотезу можно будет подтвердить по QQ-кривым и правилу 3х сигм

QQ-линии



Данные графики помогают выявить переменные, подчиняющиеся нормальному распределению. Чем больше расположение точек походит на прямую, отмеченную пунктиром, тем больше оснований полагать, что переменная подчиняется нормальному распределению. Тут подтверждается теория о нормальности распределения параметров плотности и pH

Ниже проверка на выполнение правила трех сигм для этих параметров:

density

1 sigma(s)

theoretical: 0.6826894921370859

sample: 0.7279549718574109

2 sigma(s)

theoretical: 0.9544997361036416

sample: 0.949343339587242

3 sigma(s)

theoretical: 0.9973002039367398

sample: 0.9887429643527205

pH

1 sigma(s)

theoretical: 0.6826894921370859

sample: 0.7104440275171983

2 sigma(s)

theoretical: 0.9544997361036416


sample: 0.9530956848030019

3 sigma(s)

theoretical: 0.9973002039367398

sample: 0.9949968730456535

Pairplot



Из данных графиков можно заметить два наблюдения

1. В датасете преобладают два вида красного вина: с качеством на 5 и с качеством на 6 (видно невооруженным взглядом из-за преобладания этих двух цветов)
2. Если приглядеться к параметру алкоголя, то можно заметить, что низкое его содержание приводит к ухудшению качества вина и наоборот

Выводы

1. параметры свободных и общих оксидов серы, нелетучие кислоты и pH вместе с плотностью и лимонной кислотой имеют высокую корреляцию
2. Параметры плотности и pH имеют нормальное распределение
3. В датасете преобладают два вида красного вина: с качеством на 5 и с качеством на 6
4. Низкое его содержание приводит к ухудшению качества вина и наоборот